Đề 06 · Nhập môn Công nghệ nền tảng (RIPT1304) · Tài liệu học nội bộ, không nộp

Hiểu và làm chủ phần việc của Phạm Hải Đăng

Sinh viên 1 · Trưởng nhóm kỹ thuật, Solution Architect, Platform/DevOps, Observability, Backend, DBA, phụ trách bảo mật

Bạn giữ phần "xương sống": tính tài nguyên, chọn kiến trúc, dựng lab, viết API học liệu, gắn giám sát và sửa điểm nghẽn. Thầy hay hỏi kiến trúc chung, nên bạn cần nắm cả phần của 3 bạn còn lại ở mức trả lời được.

Mục lục

1. Phần 1. Kiến thức nền cả nhóm phải nắm
2. Phần 2. Phần việc của bạn
3. Phần 3. Bảng tính tài nguyên: hiểu từng con số
4. Phần 4. Kiến trúc: vì sao chọn như vậy
5. Phần 5. Lab Kubernetes, tự mở rộng, giám sát
6. Phần 6. Điểm nghẽn, cải tiến và API học liệu
7. Phần 7. Sửa và cấu hình trực tiếp
8. Phần 8. Chạy lại và số liệu của bạn
9. Phần 9. Câu hỏi vấn đáp
0. Phần 10. Việc cần làm trước khi nộp và bảo vệ

> Cách đọc: đọc phần 1 trước (kiến thức nền chung, ai cũng phải nắm), rồi đọc lần lượt các phần riêng của bạn. Chỗ nào có **[mở trên GitHub]** là bấm được, mở đúng tệp và đúng dòng trong repo. Đoạn cấu hình trong tài liệu được trích thẳng từ tệp thật, số dòng bên trái là số dòng trong tệp.

Phần 1. Kiến thức nền cả nhóm phải nắm

1.1 Đề bài yêu cầu gì

Đề 06 của môn yêu cầu: **thiết kế một nền tảng học trực tuyến cho 1.000 sinh viên**. "Thiết kế" ở đây không phải vẽ giao diện, mà là trả lời bằng số các câu hỏi của người làm hệ thống:

- 1.000 sinh viên thì **cùng lúc có bao nhiêu người** dùng? Cần bao nhiêu **băng thông** (đường truyền mạng), bao nhiêu **dung lượng lưu trữ**?
- Hệ thống gồm những phần nào, nối với nhau ra sao (**kiến trúc**)?
- Dựng thử được không, **đo** được không: chậm ở đâu, chịu được bao nhiêu người?
- Khi hỏng (máy chết, mất dữ liệu) thì **khôi phục** thế nào, mất bao lâu, mất bao nhiêu dữ liệu?

Phiếu đề chia thành 4 yêu cầu và 3 bài kiểm thử. Nhóm gọi bằng lời thường như sau:

Phần của đề	Nội dung	Ai lo chính
Yêu cầu 1: thiết kế	Thiết kế web, dữ liệu, video, đăng nhập; phân biệt **tổng tài khoản** với **số người dùng cùng lúc**	Đăng
Yêu cầu 2: tính tài nguyên	Tính băng thông, lưu trữ cho ít nhất 2 tình huống, ghi rõ mọi giả định	Đăng
Yêu cầu 3: triển khai	Dựng 1 web học liệu nhỏ có ít nhất 3 tài nguyên (video, PDF, bài nghe); thử 3 mức tải	Thành (web), Đăng (lab)
Yêu cầu 4: đo và đề xuất	Đo thời gian trả lời, số request mỗi giây, lỗi, CPU/RAM; chỉ ra điểm nghẽn; sao lưu; phân quyền	Vân Anh (đo), Đức (sao lưu, quyền)
Kiểm thử 1	Máy khách mở được trang và tải đúng học liệu	Vân Anh, Thành
Kiểm thử 2	Chạy 3 mức tải, ghi số liệu, điều kiện đo lặp lại được	Vân Anh
Kiểm thử 3	Dừng dịch vụ rồi khôi phục; kiểm tra học liệu và thời gian gián đoạn	Đức

Hồ sơ phải nộp (mục "Hồ sơ nộp chung" của phiếu đề): báo cáo nhóm 12–18 trang; sơ đồ và bảng tài nguyên/IP/quyền; cấu hình, script, mã nguồn; README hướng dẫn dựng lại; bảng kiểm thử có giờ chạy; dữ liệu đo gốc; video demo 5–7 phút; báo cáo cá nhân. Tất cả nằm trong thư mục ho-so-nop.

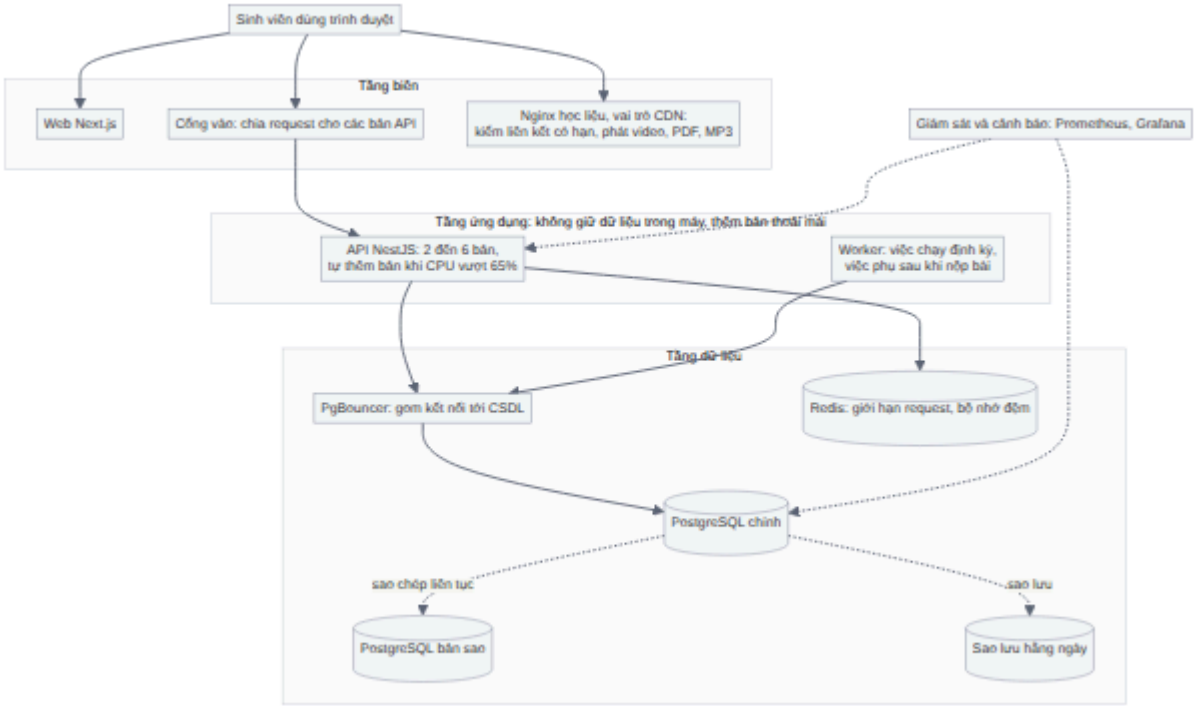
Buổi bảo vệ: mỗi người trình bày phần mình, **mở minh chứng** (tệp kết quả), **làm 1 thao tác hoặc sửa 1 thay đổi nhỏ** ngay trước mặt thầy, rồi **trả lời vấn đáp** (thầy có thể hỏi cả kiến trúc chung). Điểm cá nhân chiếm 50/100: 15 điểm phần kỹ thuật có bằng chứng, 15 điểm giải thích và thao tác trực tiếp, 20 điểm vấn đáp. Tài liệu này giúp bạn làm tốt cả 3 việc đó.

> Hanni chỉ là **hệ thống minh hoạ** (web học tiếng Trung mà Đăng viết từ trước). Thứ được chấm là cách nhóm thiết kế, đo, khôi phục, mở rộng, chứ không phải tính năng học tiếng Trung.

1.2 Hệ thống gồm những phần nào (ví như một quán ăn)

Hãy hình dung hệ thống như một quán ăn đông khách:

Phần trong hệ thống	Ví như	Làm gì
Trình duyệt của sinh viên	Khách hàng	Gửi yêu cầu, nhận kết quả, hiện lên màn hình
Web (Next.js, trang `/hoc-lieu`)	Thực đơn và bàn ăn	Phần giao diện sinh viên nhìn thấy, bấm vào
API (NestJS)	Bếp	Nhận yêu cầu ("cho tôi danh sách học liệu"), xử lý, trả kết quả. Chạy nhiều bản như nhiều đầu bếp
CSDL PostgreSQL	Kho nguyên liệu, sổ sách	Nơi giữ dữ liệu thật: tài khoản, tiến độ học, bài thi. Mất là mất thật
Redis	Bảng ghi chú dán tường	Ghi tạm những thứ cần đọc nhanh, mất cũng dựng lại được (bộ đếm giới hạn, bộ nhớ đệm)
PgBouncer	Người giữ cửa kho	Gom yêu cầu vào kho của nhiều đầu bếp, chỉ cho một số lượng cố định vào cùng lúc để kho không quá tải
Nginx học liệu (vai CDN)	Quầy phát đồ đóng gói sẵn	Phát thẳng video, PDF, MP3 cho khách, không bắt bếp phải làm. Khách phải có "phiếu" (liên kết có hạn)
Worker	Nhân viên hậu cần	Làm việc nền: nhắc học hằng ngày, xử lý việc phụ sau khi nộp bài
Giám sát (Prometheus, Grafana, Alertmanager)	Camera và chuông báo	Đo mọi thứ liên tục, vẽ biểu đồ, kêu khi có sự cố
Sao lưu	Bản photo sổ sách cất két	Mỗi ngày chép CSDL và học liệu ra chỗ khác để hỏng còn lấy lại được



Hình 1. Kiến trúc đề xuất cho 1.000 sinh viên (tệp gốc: ho-so-nop/so-do-va-bang/kien-truc-dich.png)

Ba tầng trong hình: tầng biên (web, cổng vào, Nginx học liệu) là chỗ khách đi vào; tầng ứng dụng (API, worker) là chỗ xử lý; tầng dữ liệu (PostgreSQL, Redis, sao lưu) là chỗ giữ dữ liệu. Ý quan trọng nhất: **tầng ứng dụng không giữ dữ liệu trong máy**, mọi thứ cần nhớ đều nằm ở CSDL hoặc Redis, nên muốn chịu nhiều người hơn chỉ cần **thêm bản API**, không phải sửa code.

1.3 Từ điển thuật ngữ (đọc kỹ, gặp lại ở khắp tài liệu)

Mạng và web

- **Request (yêu cầu)**: một lần trình duyệt hỏi máy chủ, ví dụ "cho tôi danh sách học liệu". Mỗi lần bấm nút có thể sinh ra vài request.
- **Response (trả lời)**: máy chủ đáp lại request, kèm một **mã trả về** (mã HTTP) cho biết kết quả.
- **API**: tập các "cửa" mà máy chủ mở ra để trình duyệt gọi vào, mỗi cửa là một **route** (đường dẫn), ví dụ `GET /api/resources` (lấy danh sách học liệu), `POST /api/resources/:id/link` (xin liên kết tải). `GET` là đọc, `POST` là gửi hoặc tạo mới.
- **Mã trả về HTTP** hay gặp trong dự án:

Mã	Nghĩa	Gặp ở đâu trong dự án
200	Thành công	Gọi API bình thường
401	Chưa đăng nhập	Khách xin liên kết video cần đăng nhập
403	Đã biết là ai nhưng không có quyền, hoặc chữ ký sai	Sửa chữ ký liên kết học liệu; người học gọi chức năng quản trị
404	Không có thứ này (hoặc giấu đi cho an toàn)	Gọi `/api/metrics` từ ngoài
410	Đã từng có nhưng hết hạn	Dùng liên kết học liệu đã quá 10 phút
429	Gửi quá nhiều, chờ chút rồi thử lại	Một tài khoản gọi quá 300 request trong 1 phút
503	Máy chủ đang quá tải hoặc chưa sẵn sàng, "thử lại sau"	Cơ chế từ chối khi quá tải của nhóm; API mất CSDL
5xx khác (500, 502…)	Lỗi máy chủ thật	Trong các lượt đo chính thức: 0 lỗi loại này

- **Băng thông**: lượng dữ liệu đi qua đường mạng mỗi giây, đơn vị **Mbps** (megabit mỗi giây). Chú ý: 8 bit = 1 byte, nên 8 Mbps = 1 MB mỗi giây. Video 540p của nhóm là 2 Mbps, tức mỗi giây xem tốn khoảng 0,25 MB.

Máy chủ

- **CPU, lõi (core)**: bộ xử lý. "0,25 lõi" nghĩa là được dùng một phần tư sức một lõi. Trong Kubernetes viết `250m` (250 phần nghìn lõi).
- **RAM**: bộ nhớ đang làm việc, viết `256Mi` (256 mebibyte, gần bằng 256 MB). Hết RAM thì máy phải dùng **swap** (lấy ổ đĩa làm RAM tạm), chậm hẳn đi; vì vậy lần đo nào máy bị swap thì nhóm bỏ, đo lại.
- **Tiến trình**: một chương trình đang chạy, ví dụ 1 bản API là 1 tiến trình Node.js.
- **Event loop (vòng xử lý của Node.js)**: Node.js xử lý mọi request bằng một vòng lặp duy nhất. Khi CPU quá bận, vòng này bị **trễ** (event loop lag): request phải xếp hàng chờ dù chưa cần tới CSDL.

Nhóm đo độ trễ này để biết API đang quá tải.

Docker và Kubernetes

- **Docker, container, image**: Docker đóng gói một chương trình cùng mọi thứ nó cần vào một **image** (như hộp cơm đóng sẵn). Chạy image lên thành **container** (hộp cơm đang được ăn). Nhờ vậy máy nào có Docker cũng chạy được giống hệt nhau. Mọi công cụ của lab (k6, ffmpeg, kubectl) đều chạy trong container nên máy không phải cài gì thêm.
- **Kubernetes**: phần mềm **quản lý nhiều container** trên nhiều máy: tự bật lại container chết, tự thêm bản khi đông, chia request đều. **k3s** là bản Kubernetes nhẹ, nhóm chạy nó ngay trong Docker để dựng lab trên 1 máy.
- **Cụm (cluster)**: tập các máy Kubernetes quản lý. **Node**: mỗi máy trong cụm. Lab có 2 node: `k3s-server` (172.25.0.2) và `k3s-agent` (172.25.0.3).
- **Pod**: đơn vị nhỏ nhất Kubernetes chạy, thường là 1 container. 1 bản API = 1 pod.
- **Deployment**: bản mô tả "tôi muốn chạy N pod giống nhau từ image X". Kubernetes giữ đúng N pod, chết cái nào tạo lại cái đó.
- **Bản (replica)**: mỗi pod giống nhau trong một Deployment. "API chạy 6 bản" là 6 pod API cùng phục vụ.
- **Service**: một địa chỉ cố định đứng trước nhiều pod, chia request cho các pod đó. Pod chết, đổi địa chỉ, Service vẫn giữ nguyên.
- **Ingress (cổng vào)**: cửa chính từ ngoài vào cụm, xem đường dẫn để đưa request tới đúng Service (`api.hanni.localhost` tới API, `media.hanni.localhost` tới Nginx học liệu). Lab dùng Traefik làm cổng vào, mở ở `127.0.0.1:18080`.
- **Namespace**: ngăn chia trong cụm. Ứng dụng nằm ở `hanni`, giám sát nằm ở `observability`.
- **Manifest (tệp YAML)**: tệp mô tả thứ muốn chạy (Deployment, Service…). Nhóm sửa manifest rồi **apply** (nạp) vào cụm.
- **kubectl**: lệnh điều khiển cụm. Trong lab gọi qua `scripts/kubectl` (đã nối sẵn vào lab). Vài lệnh hay dùng: `scripts/kubectl -n hanni get pods` (xem các pod), `get hpa` (xem tự mở rộng), `logs <tên pod>` (xem nhật ký).
- **HPA (tự mở rộng)**: Horizontal Pod Autoscaler, cứ 15 giây đo CPU trung bình các bản API; vượt ngưỡng (65% mức CPU yêu cầu) thì thêm bản, thấp lâu thì bớt, trong khoảng 2–6 bản.
- **Probe (kiểm tra sức khoẻ)**: Kubernetes định kỳ gọi thử vào pod. **Readiness** hỏi "sẵn sàng nhận khách chưa?", chưa thì tạm không chia request cho pod đó. **Liveness** hỏi "còn sống không?", nhiều lần không trả lời thì khởi động lại pod.

Dữ liệu

- **CSDL (cơ sở dữ liệu) PostgreSQL**: nơi lưu dữ liệu dạng bảng (bảng `User`, `ReviewLog`…), mỗi dòng là một bản ghi.
- **Kết nối CSDL, pool**: mỗi lần API nói chuyện với CSDL phải dùng một **kết nối**. Pool là "hồ" kết nối mở sẵn để dùng lại. CSDL chỉ chịu được một số kết nối nhất định; hết kết nối thì request phải **xếp hàng chờ**, đây là điểm nghẽn đầu tiên nhóm đo được.
- **Bản sao (replica) CSDL**: một CSDL thứ hai liên tục chép theo CSDL chính, dùng để đọc bớt và để dự phòng khi CSDL chính hỏng.
- **WAL (nhật ký thay đổi)**: PostgreSQL ghi mọi thay đổi vào nhật ký trước. Nhờ nhật ký này mà bản sao chép theo được, và có thể khôi phục về **đúng một thời điểm** trước khi xoá nhầm.

- **Redis**: kho dữ liệu cực nhanh nằm trong RAM, dùng cho thứ mất cũng không sao: bộ đếm giới hạn request, bộ nhớ đệm.
- **Bộ nhớ đệm (cache)**: lưu tạm kết quả đã tính để lần sau trả ngay, không phải tính lại. Nhóm lưu tạm "khung lộ trình học" 60 giây.

Đo hiệu năng

- **Tải**: lượng người và request đổ vào hệ thống. Đo bằng **request/giây** hoặc **lượt/giây** (1 lượt mở bài = 5 request đọc).
- **Người dùng cùng lúc (phiên đồng thời)**: số người đang thật sự dùng ở cùng một thời điểm. 1.000 tài khoản không có nghĩa 1.000 người cùng lúc: tự học rải rác chỉ khoảng **63 người**, cả lớp xem video 300, thi thử đồng loạt 600.
- **Định luật Little**: số người cùng lúc = số người bắt đầu mỗi phút × số phút mỗi người ở lại. Ví như quán ăn: mỗi phút có 2,5 khách vào, mỗi khách ngồi 25 phút, thì lúc nào cũng có khoảng 63 khách trong quán.
- **Thời gian trả lời** (độ trễ): từ lúc gửi request tới lúc nhận trả lời, đơn vị **ms** (mili giây, 1.000 ms = 1 giây).
- **p50, p95, p99 (phân vị)**: xếp thời gian trả lời của mọi request từ nhanh tới chậm. **p95 = 40 ms** nghĩa là 95% request nhanh hơn 40 ms, 5% chậm hơn. Nhóm dùng p95 vì **trung bình** bị số đông nhanh che mất những người phải chờ lâu.
- **Thông lượng**: số request trả lời được mỗi giây.
- **Tỉ lệ lỗi**: phần trăm request bị lỗi.
- **SLO (ngưỡng đạt)**: mức chất lượng nhóm tự đặt ra: **95% lượt đọc dưới 300 ms, 95% lượt ghi dưới 500 ms, lỗi dưới 0,5%**. Đo mà vượt ngưỡng là "không đạt".
- **Điểm gãy**: mức tải cao nhất còn đạt SLO; tăng quá đó là chậm vọt. Lab đo được khoảng 40 lượt/giây (khoảng 200 request/giây).
- **Điểm nghẽn (nút thắt)**: bộ phận bị đầy đầu tiên khiến cả hệ thống chậm. Như con đường: chỗ hẹp nhất quyết định xe chạy được bao nhiêu.
- **Từ chối khi quá tải**: khi quá tải, API trả lời ngay mã 503 "thử lại sau" cho một phần lượt đọc, thay vì nhận hết rồi bắt tất cả chờ 5 giây. Người được phục vụ thì nhanh, người bị từ chối thì biết để thử lại.
- **k6**: công cụ **giả lập nhiều người dùng** gửi request đều đặn rồi đo thời gian trả lời. Nhóm viết **kịch bản** k6 bằng JavaScript.
- **Lab**: môi trường đo riêng của nhóm (cụm k3s 2 node trong Docker, dữ liệu giả 1.000 tài khoản), tách hẳn web thật để đo không ảnh hưởng người dùng.
- **GitHub Actions**: dịch vụ của GitHub cho mượn máy ảo chạy lệnh tự động. Laptop của nhóm không đủ RAM nên **số đo chính thức** chạy trên máy ảo GitHub (4 nhân, 16 GB) ngày 09/11/2026; máy ảo dựng lại lab từ đầu theo README rồi mới đo.

Giám sát và sao lưu

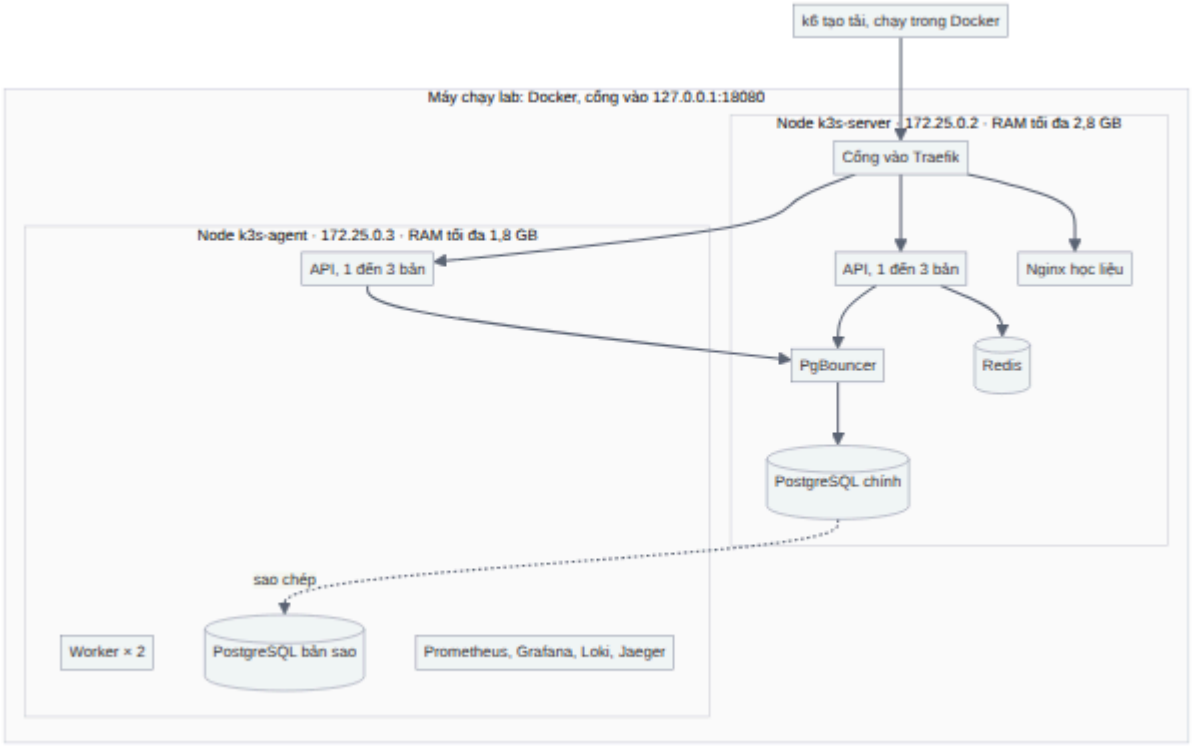
- **Prometheus**: cứ vài giây hỏi số liệu của từng thành phần (API, CSDL, Redis) rồi lưu lại theo thời gian.
- **Grafana**: vẽ số liệu của Prometheus thành biểu đồ. Nhóm có 3 bảng: chất lượng dịch vụ, mở rộng (số bản API, CPU), dữ liệu.

- **Alertmanager**: gửi cảnh báo khi một luật bị vi phạm, ví dụ "từ ngoài gọi API không được quá 30 giây".
- **Blackbox (dò từ ngoài)**: một chương trình đứng ngoài gọi thử API mỗi vài giây như một sinh viên thật, để biết sinh viên có vào được không.
- **Loki, Jaeger**: Loki gom nhật ký (log) của mọi pod; Jaeger lần theo đường đi của một request qua các phần.
- **Sao lưu (backup)**: chép dữ liệu ra một bản riêng để khi hỏng lấy lại được. **Khôi phục (restore)**: đưa bản sao lưu trở lại.
- **RPO**: lượng dữ liệu tối đa có thể mất, tính từ lần sao lưu gần nhất. Sao lưu mỗi ngày thì RPO tối đa 1 ngày.
- **RTO**: thời gian từ lúc hỏng tới lúc dùng lại được. Lab đo được RTO 52 giây khi xoá hẳn CSDL.
- **Mã băm SHA-256**: "dấu vân tay" của tệp, một chuỗi 64 ký tự tính từ nội dung. Sai một byte là chuỗi khác hẳn, nên so mã băm biết tệp tải về hay khôi phục ra có đúng y nguyên không.

Công cụ dựng lab

- **make, Makefile**: `make up` là chạy một nhóm lệnh đã viết sẵn trong tệp `Makefile`. Nhóm có `make up`, `make images`, `make deploy`, `make seed`, `make observability`, `make status`, `make stop`, `make start`, `make down`.
- **YAML**: định dạng các tệp cấu hình. Quy tắc: `khoá: giá trị`, **thụt lề bằng dấu cách** thể hiện cấp (sai thụt lề là hỏng tệp), dòng bắt đầu bằng `#` là ghi chú, chuỗi số nên để trong ngoặc kép như `"600"`.

1.4 Lab của nhóm trông như thế nào



Hình 2. Sơ đồ lab: 2 node, địa chỉ IP và các thành phần (tệp gốc: ho-so-nop/so-do-va-bang/so-do-lab.png)

Thành phần	Địa chỉ	Ghi chú
Node k3s-server	172.25.0.2	RAM tối đa 2,8 GB
Node k3s-agent	172.25.0.3	RAM tối đa 1,8 GB
Cổng vào (ingress)	127.0.0.1:18080	Mọi địa chỉ dưới đây đi qua cổng này
API	http://api.hanni.localhost:18080/api/health	
Grafana	http://grafana.hanni.localhost:18080	Tài khoản `admin`, mật khẩu lấy bằng lệnh ở README
Prometheus	http://prometheus.hanni.localhost:18080	
Alertmanager	http://alertmanager.hanni.localhost:18080	
Web	http://hanni.localhost:3000	Chạy riêng bằng `npx next dev`

1.5 Repo này có gì, phần của mình ở đâu

Đường dẫn	Nội dung
ho-so-nop/bao-cao/	Báo cáo nhóm (.docx, .pdf), 4 báo cáo cá nhân theo mẫu của thầy
ho-so-nop/so-do-va-bang/	2 sơ đồ, bảng tài nguyên/IP/quyền kèm bảng tính tài nguyên
ho-so-nop/cau-hinh-ma-nguon/hanni-server/infra/	**Toàn bộ cấu hình lab**: k8s/ (Kubernetes), k6/ (kịch bản tải), scripts/ (script kiểm thử, sao lưu), observability/ (giám sát), media/ (học liệu)
ho-so-nop/cau-hinh-ma-nguon/hanni-server/src/	Mã API nhóm viết cho đề: học liệu, số liệu đo, giới hạn request, từ chối khi quá tải
ho-so-nop/cau-hinh-ma-nguon/hanni-client/	Trang web học liệu và test tự động
ho-so-nop/data/raw/	Dữ liệu đo gốc, không sửa tay. `gha-09-11/` là lượt đo chính thức
ho-so-nop/evidence/	Minh chứng: ảnh chụp, nhật ký, danh sách mã băm. Danh mục ở `evidence/README.md`
ho-so-nop/bang-kiem-thu.xlsx	Bảng kiểm thử 62 dòng có giờ chạy
ho-so-nop/video-demo.mp4	Video demo 6 phút
Hanni-RIPT1304-Phan-cong.xlsx	Sheet phân công: việc của từng người, tiến độ, tab **Ôn vấn đáp**

Mã nguồn đầy đủ (chạy được) ở 2 repo: hanni-server nhánh feat/scaling và hanni-client nhánh feat/hoc-lieu. Thư mục `cau-hinh-ma-nguon/` chỉ là bản trích các tệp nhóm viết cho đề.

1.6 Dựng lab trên máy của bạn

Cần: Docker (kèm Docker Compose), `make`, `git`, còn trống khoảng 3 GB RAM và 8 GB đĩa. Windows thì dùng WSL 2.

```
git clone -b feat/scaling https://github.com/DANG-PH/hanni-server.git
cd hanni-server/infra
make up              # tạo học liệu mẫu, bật 2 node k3s, sinh mật khẩu ngẫu nhiên
make images          # build image API rồi nạp vào 2 node
make deploy          # chạy PostgreSQL + bản sao, PgBouncer, Redis, API, worker, Nginx học liệu, tự
mở rộng, chặn mạng
make seed            # tạo bảng, nạp từ vựng, tạo 1.000 tài khoản giả
make observability   # chạy Prometheus, Alertmanager, Grafana, Loki, Jaeger
make status          # mọi pod phải ở trạng thái Running
```

Lần đầu mất 10–20 phút vì phải tải image; các lần sau khoảng 4–5 phút. Tạm tắt cho nhẹ máy: `make stop`, bật lại: `make start`, xoá sạch: `make down`. Nếu máy yếu không dựng nổi, nhờ Đăng chạy trên GitHub Actions (đẩy nhánh lên `do-lab` là máy ảo tự dựng và đo).

1.7 Quy tắc chung khi sửa cấu hình

1. Mở tệp cần sửa trong `hanni-server/infra` (đường dẫn ở bảng "Sửa nhanh" của phần riêng bạn), sửa đúng dòng, giữ nguyên thụt lề.
2. Nạp lại vào cụm: `make deploy`.
3. Nếu đã sửa `k8s/app/config.yaml` hoặc `k8s/media-manifest.json` thì chạy thêm `scripts/kubectl -n hanni rollout restart deployment/hanni-api`, vì API chỉ đọc 2 tệp này lúc khởi động.
4. Nếu đã sửa luật cảnh báo trong `observability/` thì chạy `make observability` rồi `scripts/kubectl -n observability rollout restart deployment/prometheus`.
5. **Kiểm tra lại** bằng lệnh hoặc trang ghi ở cột "Kiểm tra" và nói được kết quả thay đổi thế nào.

> Khi thầy bảo "đổi X rồi chạy lại", hãy nói to 3 ý: (1) X nằm ở tệp nào, dòng nào; (2) đổi xong thì hệ thống sẽ thay đổi gì; (3) lệnh nào kiểm tra được điều đó. Làm như vậy là ăn trọn điểm "giải thích và thao tác trực tiếp".

Phần 2. Phần việc của bạn

2.1 Phiếu đề giao gì cho bạn

Phiếu đề ghi Sinh viên 1 lo **"Kiến trúc và bảng tính tài nguyên"**. Trong nhóm, bạn làm thêm phần nền mà 3 bạn kia đứng lên trên:

Vai trò	Bạn làm gì	Phục vụ phần nào của đề
Solution Architect	Chọn kiến trúc 3 tầng, tính số người cùng lúc, băng thông, lưu trữ	Yêu cầu 1, Yêu cầu 2
Platform/DevOps	Dựng lab k3s 2 node trong Docker, tự mở rộng số bản API	Yêu cầu 3 (môi trường để thử 3 mức tải)
Observability	Prometheus, Grafana, Alertmanager, dò từ ngoài	Yêu cầu 4 (đo CPU/RAM, thời gian trả lời), Kiểm thử 3 (cảnh báo)
Backend	API học liệu ký liên kết có hạn; cải tiến theo điểm nghẽn	Yêu cầu 3, Yêu cầu 4
DBA	PostgreSQL, bản sao đọc, PgBouncer, chia bảng lớn, khôi phục về đúng thời điểm	Yêu cầu 1 (dữ liệu), Yêu cầu 4
Bảo mật	Ma trận quyền, chặn mạng trong cụm	Yêu cầu 4 (kiểm soát truy cập)
Trưởng nhóm kỹ thuật	Chia việc, rà sản phẩm, nộp hồ sơ	Hồ sơ nộp

2.2 Sản phẩm của bạn trong hồ sơ

- Bảng tính tài nguyên: so-do-va-bang/bang-tai-nguyen-ip-quyen.xlsx, tab "Tính tài nguyên".
- Sơ đồ: kien-truc-dich.png, so-do-lab.png.
- Cấu hình lab: infra/, đặc biệt k8s/ và compose.yaml.
- Mã API: modules/resources/ (học liệu), infra/metrics/ (số liệu đo, từ chối khi quá tải).
- Báo cáo cá nhân: Lop_Nhom_06_MSSV_PhamHaiDang_BaoCaoCaNhan.docx.

Phần 3. Bảng tính tài nguyên: hiểu từng con số

Bảng tính trả lời Yêu cầu 1 và 2 của đề: **1.000 tài khoản cần bao nhiêu tài nguyên**. Mở tệp bang-tai-nguyen-ip-quyen.xlsx, tab "Tính tài nguyên". Ô **chữ xanh** là giả định (sửa được), ô **chữ đen** là công thức (tự tính lại).

3.1 Vì sao phải tách "tài khoản" với "người dùng cùng lúc"

1.000 sinh viên có tài khoản không có nghĩa 1.000 người bấm cùng một giây. Thứ tạo ra tải là số người **đang dùng cùng lúc**. Con số này khác nhau theo tình huống, nên nhóm tính 3 tình huống:

Tình huống	Hình dung	Cách tính
Tự học hằng ngày	Mỗi người tự vào học lúc rảnh, rải rác trong ngày	Định luật Little
Cả lớp xem video cùng giờ	Giảng viên cho cả lớp xem bài giảng trong buổi học	Tỷ lệ 30% tài khoản
Thi thử đồng loạt	Cả khoá mở đề cùng giờ, nộp sát giờ hết	Tỷ lệ 60% tài khoản

3.2 Tính từng bước (tự làm lại được bằng tay)

Tự học, theo định luật Little (số người cùng lúc = số người bắt đầu mỗi phút × số phút mỗi người ở lại):

1. Mỗi ngày 30% tài khoản vào học: 1.000 × 30% = **300 người**.
2. Một nửa số đó dồn vào giờ cao điểm 1 giờ (60 phút): 300 × 50% = 150 người trong 60 phút, tức **2,5 người bắt đầu mỗi phút**.
3. Mỗi người học 25 phút. Số người cùng lúc = 2,5 × 25 = 62,5, làm tròn lên **63 người**.

Băng thông 1 người xem video: 60% xem 540p (2 Mbps video + 0,128 Mbps tiếng), 40% xem 720p (3 + 0,128): 0,6 × 2,128 + 0,4 × 3,128 = **2,528 Mbps**.

Cả lớp xem video: 1.000 × 30% = **300 người** cùng lúc, trong đó 90% đang xem video = 270 người.

- Băng thông video: 270 × 2,528 ≈ 682,6 Mbps.
- 30 người không xem video chỉ gọi API và nghe ghi âm, mỗi người 0,02 Mbps: thêm khoảng 0,6 Mbps.
- Tổng 683,2 Mbps, cộng **30% dự phòng** (chừa cho lúc đông đột biến và sai số): 683,2 × 1,3 = **888,1 Mbps**.

Thi thử: 600 người mở đề trong 60 giây = **10 request/giây**; nộp bài trong 30 giây = **20 request/giây**. Băng thông nhỏ (6,2 Mbps) vì đề nhẹ, lúc làm bài đáp án nằm ở trình duyệt.

3.3 Kết luận rút ra (phải nói được khi bảo vệ)

- **Phần tốn nhất là băng thông video**, không phải API: cả lớp xem cần khoảng 888 Mbps, trong khi API chỉ khoảng 56 request/giây. Vì vậy video **không được đi qua API**: API chỉ ký liên kết, Nginx (thực tế là CDN) phát tệp.
- Nếu không tự lưu video thì dung lượng rất nhỏ, khoảng 14,8 GB.
- Rủi ro thật nằm ở **các đợt đồng loạt** (mở đề, nộp bài, đăng nhập), không ở số trung bình.

3.4 Đối chiếu giả định với số đo thật

Thành ghi lại mọi request của 1 phiên học bằng HAR: **20 request API, trung bình 2 KB mỗi request**. Bảng tính giả định 8 KB, lớn hơn 4 lần, nên băng thông API trong bảng tính là **con số dư, an toàn**. Bạn giữ giả định cũ vì người học nhanh hay chậm làm tần suất request thay đổi.

3.5 Tình huống thầy hay hỏi: đổi giả định

Thầy hỏi	Bạn sửa ô nào	Kết quả thay đổi
Số sinh viên tăng gấp đôi	"Tổng tài khoản": 1000 → 2000	Số người cùng lúc, băng thông, số bản API gấp đôi theo
Video lên 1080p	Thêm bitrate cao hơn ở "Bitrate video 720p" (ví dụ 5 Mbps)	Băng thông 1 người xem và cả lớp tăng
Bớt dự phòng còn 10%	"Phần dự phòng": 30% → 10%	Mọi dòng "kèm dự phòng" giảm
Lên 10.000 hay 100.000	Xem phần cuối tab, bảng "Theo quy mô"	Số bản API: 100 → 2, 1.000 → 2, 10.000 → 5, 100.000 → 50

Phần 4. Kiến trúc: vì sao chọn như vậy

4.1 Mỗi lựa chọn kiến trúc và lý do

Lựa chọn	Vì sao	Đánh đổi (phải nói được)
Video không đi qua API, Nginx/CDN phát	Cả lớp xem cần gần 900 Mbps, API không cần gánh	Phụ thuộc CDN
Giữ 1 ứng dụng, không tách nhiều dịch vụ nhỏ	Tải ở mức này chưa cần; mỗi dịch vụ thêm là thêm việc vận hành	Không mở rộng riêng từng phần
API không giữ dữ liệu trong máy	Thêm bản là chạy ngay, bản nào chết cũng không mất gì	Mọi trạng thái phải nằm ở CSDL hoặc Redis
PostgreSQL giữ dữ liệu thật, Redis chỉ giữ thứ dựng lại được	Mất Redis không mất dữ liệu học	Phải xử lý dữ liệu đệm cũ
Tách worker khỏi API	Chạy nhiều bản API mà việc định kỳ không bị chạy trùng	Thêm 1 tiến trình phải theo dõi
Giới hạn request theo tài khoản, đếm trong Redis	Cả phòng máy chung 1 địa chỉ IP không bị chặn lây	Thêm 1 lần gọi Redis mỗi request
PgBouncer đứng trước PostgreSQL	Thêm bản API thì tổng kết nối không tăng theo	Thêm 1 thành phần
Có bản sao CSDL nhưng mặc định đọc bản chính	Không đọc phải dữ liệu cũ ngay sau khi vừa ghi	Bản sao chỉ dùng cho trang xếp hạng

4.2 Vì sao "API không giữ dữ liệu trong máy" lại quan trọng nhất

Giả sử API nhớ "người A đã gửi 5 request" ngay trong bộ nhớ của nó. Khi có 6 bản API, request của A rơi ngẫu nhiên vào 6 bản, mỗi bản chỉ thấy một phần, đếm sai. Vì vậy nhóm đã chuyển mọi thứ cần nhớ ra ngoài:

- Bộ đếm giới hạn request: vào **Redis** (`THROTTLE_SCOPE: user`).
- Việc chạy định kỳ (nhắc học, giải đấu tuần): sang **worker**, có khoá Redis để mỗi chu kỳ chỉ 1 bản làm (`CRON_LEASE`).
- Kết nối CSDL: qua **PgBouncer**, nên 6 bản × 10 kết nối = 60 không đè lên giới hạn của PostgreSQL.

Nhờ vậy, muốn chịu nhiều người hơn chỉ cần tăng số bản API, Kubernetes tự làm.

4.3 PgBouncer làm gì, giải thích bằng số

PostgreSQL lab đặt tối đa **60 kết nối**. Mỗi bản API mở tối đa 10 kết nối (`DB_POOL_MAX: "10"`). 6 bản API + worker là 70 kết nối, vượt 60. PgBouncer đứng giữa: nhận 70 kết nối "ảo" từ API nhưng chỉ mở **20 kết nối thật** tới PostgreSQL, ai cần thì mượn rồi trả ngay sau mỗi giao dịch.

hanni-server/infra/k8s/data/pgbouncer.yaml, dòng 1–4 (mở trên GitHub):

```
# Nhiều bản API × pool 10 kết nối sẽ vượt max_connections khi HPA tăng số bản. PgBouncer giữ số kết nối thật tới
# Postgres cố định, bản API có tăng bao nhiêu cũng chỉ xếp hàng ở đây.
# Chế độ transaction: an toàn với app vì TypeORM + pg không dùng prepared statement có tên, không dùng LISTEN.
apiVersion: apps/v1
```

Phần 5. Lab Kubernetes, tự mở rộng, giám sát

5.1 Lab được dựng từ những tệp nào

Tệp	Làm gì
compose.yaml	Bật 2 node k3s bằng Docker, cố định IP, chặn RAM mỗi node
Makefile	Các lệnh `make up/images/deploy/seed/observability/status`
k8s/kustomization.yaml	Danh sách mọi manifest được nạp khi `make deploy`
k8s/app/api.yaml	API: Deployment, Service, tự mở rộng (HPA), giới hạn gián đoạn (PDB)
k8s/app/config.yaml	Biến môi trường của API, có ghi chú từng dòng
k8s/app/worker.yaml	2 worker chạy việc nền
k8s/app/media.yaml	Nginx phát học liệu (Thành phụ trách cấu hình chữ ký)
k8s/app/ingress.yaml	Cổng vào: tên miền nào tới Service nào
k8s/data/	PostgreSQL, bản sao, PgBouncer, Redis
k8s/policy/network-policy.yaml	Chặn mạng trong cụm (Đức kiểm thử)
observability/	Prometheus, Grafana, Alertmanager, Loki, Jaeger, luật cảnh báo

5.2 Hai node, IP cố định, RAM bị chặn

hanni-server/infra/compose.yaml, dòng 1–2 (mở trên GitHub):

```
   1 | # Cụm k3s 2 node chạy trong Docker, theo file compose chính thức của k3s. Chỉ cần Docker:
kubectl đã có trong
   2 | # container, gọi qua infra/scripts/kubectl. RAM mỗi node bị chặn cứng để số đo lặp lại được
và cụm không ăn hết máy.
```

Mỗi node bị chặn RAM (`mem_limit: 2800m` và `1800m`) để lần đo nào cũng cùng điều kiện và cụm không ăn hết máy. IP cố định 172.25.0.2 và 172.25.0.3 vì nếu Docker đổi IP sau khi khởi động lại máy, chứng chỉ của node không khớp và lệnh `kubectl exec` lỗi (đã gặp thật).

5.3 Đọc hiểu manifest của API

Mở k8s/app/api.yaml. Tệp có 4 phần ngăn bởi `---`: Deployment (chạy API), Service (địa chỉ cố định), HPA (tự mở rộng), PDB (giới hạn gián đoạn).

Tài nguyên mỗi bản API: `requests` là mức được đảm bảo (Kubernetes dựa vào đây để xếp pod lên node và để HPA tính phần trăm CPU), `limits` là mức trần không được vượt.

hanni-server/infra/k8s/app/api.yaml, dòng 59–65 (mở trên GitHub):

```
  59 |           resources:
  60 |             requests:
  61 |               cpu: 250m
  62 |               memory: 256Mi
  63 |             limits:
  64 |               cpu: "1"
  65 |               memory: 512Mi
```

Kiểm tra sức khoẻ: 3 loại probe. Startup chờ API khởi động (tối đa 40 × 3 giây); readiness hỏi 5 giây một lần, 3 lần không trả lời thì tạm không chia request; liveness hỏi 10 giây một lần, **6 lần liền** (khoảng 60 giây) không trả lời mới khởi động lại.

hanni-server/infra/k8s/app/api.yaml, dòng 66–88 (mở trên GitHub):

```
  66 |           startupProbe:
  67 |             httpGet:
  68 |               path: /api/health/live
  69 |               port: http
  70 |             periodSeconds: 3
  71 |             failureThreshold: 40
  72 |           # Probe phải phân biệt CHẬM với CHẾT (DDIA ch. 8). Mặc định hết giờ sau 1 giây: đo
trên lab, lúc bão hoà CPU event
  73 |           # loop trễ 800 ms, Kubernetes giết chính các bản đang làm việc, tải đổ sang bản còn
lại, thông lượng thành công tụt 43%.
  74 |           readinessProbe:
  75 |             httpGet:
  76 |               path: /api/health/ready
  77 |               port: http
  78 |             periodSeconds: 5
  79 |             timeoutSeconds: 3
  80 |             failureThreshold: 3
  81 |           # Cần 60 giây không phản hồi mới restart: restart chỉ cứu được tiến trình treo,
không cứu được tiến trình quá tải.
  82 |           livenessProbe:
  83 |             httpGet:
  84 |               path: /api/health/live
  85 |               port: http
  86 |             periodSeconds: 10
  87 |             timeoutSeconds: 5
  88 |             failureThreshold: 6
```

Vì sao liveness phải chờ lâu: mặc định Kubernetes chỉ chờ 1 giây. Lúc quá tải, API trả lời chậm khoảng 0,8–1 giây nên bị coi là "chết" và bị khởi động lại, tải dồn sang các bản còn lại, chúng lại chậm, lại bị khởi động lại: **lỗi dây chuyền**. Đo trên lab: thông lượng thành công tụt 43%. Sau khi sửa: 6/6 bản sẵn sàng, 0 lần khởi động lại. Nhớ câu: **kiểm tra sức khoẻ phải phân biệt "chậm" với "chết"**.

5.4 Tự mở rộng (HPA)

hanni-server/infra/k8s/app/api.yaml, dòng 134–165 (mở trên GitHub):

```
kind: HorizontalPodAutoscaler
metadata:
  name: hanni-api
spec:
  scaleTargetRef:
    apiVersion: apps/v1
    kind: Deployment
    name: hanni-api
  minReplicas: 2
  maxReplicas: 6
  metrics:
    - type: Resource
      resource:
        name: cpu
        target:
          type: Utilization
          averageUtilization: 65
  behavior:
    scaleUp:
      stabilizationWindowSeconds: 0
      policies:
        - type: Percent
          value: 100
          periodSeconds: 30
    # Giảm chậm: tải theo đợt (nộp bài xong tới lớp khác), giảm nhanh là vừa tắt đã phải bật lại.
    scaleDown:
      stabilizationWindowSeconds: 300
      policies:
        - type: Pods
          value: 1
          periodSeconds: 60
---
```

Đọc từng dòng:

- `minReplicas: 2`, `maxReplicas: 6`: luôn có ít nhất 2 bản (1 bản chết vẫn còn 1), tối đa 6 (lab chỉ đủ CPU cho 6).
- `averageUtilization: 65`: CPU trung bình các bản vượt 65% **mức yêu cầu** (65% × 0,25 lõi ≈ 0,16 lõi) thì thêm bản.
- `scaleUp`: thêm nhanh, mỗi 30 giây được gấp đôi số bản. `scaleDown`: bớt chậm, vì tải đến theo đợt (nộp bài xong lớp khác lại vào).

Đo thật (lượt chính thức, tăng dần tới 200 request/giây): 4 bản (giây 0) → 3 bản (giây 45) → 5 bản (giây 90) → 6 bản (giây 120).

> HPA không đỡ được đợt nộp bài 30 giây: nó đo 15 giây một lần và bản mới cần vài chục giây mới sẵn sàng. Phải tăng sẵn số bản trước giờ thi.

5.5 Giám sát

- API mở số liệu ở `/api/metrics` (chỉ trong cụm; từ ngoài gọi nhận 404). Mã ở metrics.service.ts.
- Prometheus thu số liệu mỗi vài giây; Grafana vẽ 3 bảng: **"Chất lượng dịch vụ"** (p95, tỉ lệ lỗi), **"Mở rộng"** (số bản API, CPU, hàng chờ kết nối CSDL), **"Dữ liệu"**.
- Luật cảnh báo ở observability/rules/hanni-slo.yml (Đức phụ trách phần đọc hiểu).

Phần 6. Điểm nghẽn, cải tiến và API học liệu

6.1 Điểm nghẽn tìm được như thế nào

Vân Anh tăng tải dần bằng `tang-dan.js` trên 6 bản API, xem bảng Grafana "Mở rộng". Khi vượt khoảng 157 request/giây, số request **xếp hàng chờ kết nối CSDL** tăng vọt (lúc giữ 400 request/giây có tới 430 request chờ), p95 lên **5,0 giây**. Route nặng nhất là `/learn/path` (khung lộ trình học): mỗi lượt đều đọc CSDL lấy cùng một nội dung.

6.2 Ba cải tiến

1. Lưu tạm khung lộ trình 60 giây. Ai mở lộ trình HSK 1 cũng thấy cùng khung bài, nên chỉ cần đọc CSDL 1 lần mỗi 60 giây.

hanni-server/src/modules/learn/learn.service.ts (thời gian lưu tạm), dòng 18–18 (mở trên GitHub):

```
18 | const PATH_CONTENT_TTL_MS = 60_000;
```

2. Từ chối khi quá tải. Mỗi request đọc (GET) đi qua hàm `shed`: nếu API đang quá tải thì trả ngay 503 kèm `Retry-After: 2` ("2 giây nữa thử lại"). Quá tải được nhận ra theo 2 dấu hiệu: hàng chờ kết nối CSDL dài (`SHED_POOL_WAITING`) hoặc event loop trễ (`SHED_LOOP_LAG_MS`). Lượt ghi như nộp bài **không bị từ chối**.

hanni-server/src/infra/metrics/metrics.service.ts, dòng 97–125 (mở trên GitHub):

```
  97 |   /** 2 kiểu quá tải khác nhau: thiếu kết nối CSDL thì hàng đợi pool dài ra, thiếu CPU thì
event loop trễ. */
  98 |   private overloaded(): boolean {
  99 |     const waiting = this.pool()?.waitingCount ?? 0;
 100 |     return (
 101 |       (this.shedAt > 0 && waiting >= this.shedAt) ||
 102 |       (this.shedLagMs > 0 && this.loopLagMs >= this.shedLagMs)
 103 |     );
 104 |   }
 105 |
 106 |   /**
 107 |    * Từ chối có kiểm soát: quá tải thì trả 503 kèm Retry-After cho lượt ĐỌC, giữ chỗ cho lượt
ghi như nộp bài. Đo trên lab:
 108 |    * không có bước này, quá điểm gãy thì mọi request xếp hàng, p95 lên 3,8 giây và thông
lượng tụt 40%.
 109 |    */
 110 |   shed = (req: Request, res: Response, next: NextFunction): void => {
 111 |     if (
 112 |       req.method === 'GET' &&
 113 |       this.overloaded() &&
 114 |       !req.originalUrl.includes('/health') &&
 115 |       !req.originalUrl.includes('/metrics')
 116 |     ) {
 117 |       res
 118 |         .status(503)
 119 |         .set('Retry-After', '2')
 120 |         .json({ message: 'Hệ thống đang đông, bạn thử lại sau ít giây nhé.' });
 121 |       return;
 122 |     }
 123 |     next();
 124 |   };
 125 |
```

3. Kiểm tra sức khoẻ chờ lâu hơn (mục 5.3).

6.3 Kết quả trước và sau (lượt đo chính thức 09/11/2026)

	Trước khi sửa	Sau khi sửa
Mức cao nhất còn đạt (p95 đọc dưới 300 ms)	157 request/giây	190 request/giây
Giữ 400 request/giây: 95% lượt chờ	**5,0 giây**	**0,73 giây**
Request chờ kết nối CSDL lúc quá tải	430	3,5
Kiểm thử 2 mức 36 lượt/giây: p95 ± độ lệch 3 lần	57 ± 16 ms	40 ± 2 ms

Cách nói: "Mức tối đa còn nhanh tăng khoảng 21%; quan trọng hơn, quá tải không còn làm mọi người cùng chờ 5 giây. Đánh đổi là một phần lượt đọc nhận 503 và phải thử lại sau 2 giây. Sau khi sửa, điểm nghẽn chuyển sang CPU của API, muốn hơn nữa thì thêm bản hoặc thêm máy."

6.4 API học liệu: ký liên kết có hạn

Khi bấm "Xem video", trang gọi `POST /api/resources/:id/link`. API kiểm quyền (video cần đăng nhập), rồi tạo liên kết có chữ ký và thời hạn. Nginx tự kiểm chữ ký, nên tệp đi thẳng từ Nginx tới trình duyệt, không qua API (chi tiết phần Nginx ở tài liệu của Thành).

hanni-server/src/modules/resources/resources.service.ts, dòng 56–73 (mở trên GitHub):

```
  link(id: string, user: AuthUser | undefined, now = Date.now()) {
    const entry = this.entries.find((e) => e.id === id);
    if (!entry) throw new NotFoundException('Không tìm thấy học liệu này');
    if (entry.requiresLogin && !user) {
      throw new UnauthorizedException('Bạn cần đăng nhập để mở học liệu này');
    }
    const ttl = this.config.get('RESOURCE_LINK_TTL_SEC', { infer: true });
    const expires = Math.floor(now / 1000) + ttl;
    const secret = this.config.get('RESOURCE_LINK_SECRET', { infer: true });
    const token = createHash('md5')
      .update(`${expires}/${entry.dir} ${secret}`)
      .digest('base64url');
    const base = this.config.get('RESOURCE_BASE_URL', { infer: true });
    return {
      url: `${base}/files/${token}/${expires}/${entry.dir}/${entry.file}`,
      expiresAt: new Date(expires * 1000).toISOString(),
    };
  }
```

- Dòng `requiresLogin && !user`: khách xin video cần đăng nhập thì trả 401.
- `expires`: thời điểm hết hạn = bây giờ + `RESOURCE_LINK_TTL_SEC` (600 giây).
- `token`: băm MD5 của "thời hạn/thư mục khoá-bí-mật". Ai sửa thời hạn hay thư mục trên liên kết thì chữ ký không khớp, Nginx trả 403.

Phần 7. Sửa và cấu hình trực tiếp

Bảng đầy đủ cho cả nhóm ở infra/README.md, mục "Sửa nhanh khi bảo vệ". Dưới đây là phần của bạn, có trích đoạn thật.

7.1 Đổi số bản API tối thiểu, tối đa, ngưỡng CPU

hanni-server/infra/k8s/app/api.yaml, dòng 142–150 (mở trên GitHub):

```
142 |   minReplicas: 2
143 |   maxReplicas: 6
144 |   metrics:
145 |     - type: Resource
146 |       resource:
147 |         name: cpu
148 |         target:
149 |           type: Utilization
150 |           averageUtilization: 65
```

Ví dụ thầy bảo "cho tối đa 4 bản": sửa `maxReplicas: 6` thành `4`, chạy `make deploy`, rồi `scripts/kubectl -n hanni get hpa` thấy cột MAXPODS = 4. Giải thích: ít bản hơn thì điểm gãy thấp hơn, lúc đông sẽ sớm phải trả 503.

7.2 Đổi CPU, RAM cho mỗi bản API

hanni-server/infra/k8s/app/api.yaml, dòng 59–65 (mở trên GitHub):

```
 59 |           resources:
 60 |             requests:
 61 |               cpu: 250m
 62 |               memory: 256Mi
 63 |             limits:
 64 |               cpu: "1"
 65 |               memory: 512Mi
```

Sửa `requests` / `limits`, chạy `make deploy`. Pod tự được tạo lại với mức mới (`scripts/kubectl -n hanni get pods` thấy pod mới). Lưu ý: đổi `requests.cpu` làm thay đổi cả ý nghĩa 65% của HPA.

7.3 Đổi giới hạn request mỗi tài khoản

hanni-server/infra/k8s/app/config.yaml, dòng 16–20 (mở trên GitHub):

```
 16 |   # Đếm theo tài khoản trong Redis: cả phòng máy chung 1 IP không bị chặn lây nhau.
 17 |   THROTTLE_SCOPE: user
 18 |   THROTTLE_LIMIT: "300"
 19 |   THROTTLE_TTL: "60"
 20 |   # Ingress nằm trong dải IP pod của k3s: không tin dải này thì mọi khách đều mang IP của
Traefik.
```

`THROTTLE_LIMIT` request trong `THROTTLE_TTL` giây cho mỗi tài khoản. Sửa, `make deploy`, rồi `scripts/kubectl -n hanni rollout restart deployment/hanni-api`. Kiểm tra: gọi liên tục 1 route quá ngưỡng thì nhận 429.

7.4 Đổi ngưỡng từ chối khi quá tải

hanni-server/infra/k8s/app/config.yaml, dòng 29–32 (mở trên GitHub):

```
  29 |   # Ngưỡng cho mỗi bản. Đo trên lab: tổng 56 request chờ trên 6 bản là p95 đã vượt 480 ms,
sau đó hệ thống sập dần.
  30 |   SHED_POOL_WAITING: "8"
  31 |   # Quá tải do CPU không làm dài hàng đợi CSDL nên cần thêm tín hiệu này. Đo trên lab: 195 ms
còn trong SLO, 341 ms đã vượt.
  32 |   SHED_LOOP_LAG_MS: "250"
```

Đặt `"0"` là tắt hẳn cơ chế. Sau khi sửa: `make deploy` + khởi động lại API. Kiểm tra bằng `scripts/k6.sh tang-dan.js -e MAX_RATE=80`, xem tỉ lệ 503.

7.5 Đổi thời gian lưu tạm khung lộ trình

Sửa `PATH_CONTENT_TTL_MS` trong `hanni-server/src/modules/learn/learn.service.ts` (60_000 là 60 giây). Đây là mã, nên phải build lại image: `make images`, rồi `scripts/kubectl -n hanni rollout restart deployment/hanni-api`.

7.6 Đổi giả định trong bảng tính

Mở bang-tai-nguyen-ip-quyen.xlsx, tab "Tính tài nguyên", sửa ô chữ xanh. Mọi ô kết quả tự tính lại.

Phần 8. Chạy lại và số liệu của bạn

8.1 Chạy lại phần của bạn, từng bước

1. Dựng lab theo mục 1.6. `make status` thấy mọi pod Running, `scripts/kubectl -n hanni get hpa` thấy `hanni-api` có MINPODS 2, MAXPODS 6.
2. Lấy mật khẩu Grafana: `scripts/kubectl -n observability get secret grafana-admin -o jsonpath='{.data.password}' | base64 -d`, mở http://grafana.hanni.localhost:18080, đăng nhập `admin`, mở bảng "Hanni: Mở rộng".
3. Tăng tải dần: `scripts/k6.sh tang-dan.js -e MAX_RATE=40 -e STEP=25s -e HOLD=60s`. Trên Grafana thấy số bản API tăng từ 2 lên 6.
4. Xem CPU, hàng chờ kết nối CSDL trên cùng bảng; chạy `scripts/kubectl -n hanni get hpa` để thấy TARGETS (CPU hiện tại / 65%).
5. Đổi 1 ô bảng tính, giải thích kết quả mới.

8.2 Số liệu để nói khi bảo vệ

Câu cần nói	Số
Người cùng lúc (tự học / xem video / thi thử)	63 / 300 / 600
Băng thông cả lớp xem video, có dự phòng	888,1 Mbps
Kiểm thử 2, 3 mức 10, 24, 36 lượt/giây (khoảng 50, 120, 180 request/giây)	đều đạt cả trước và sau cải tiến
Mức cao nhất còn đạt, trước → sau	157 → 190 request/giây
Quá tải 400 request/giây, 95% lượt chờ	5,0 → 0,73 giây
Tự mở rộng	4 → 3 → 5 → 6 bản
Dựng lab từ đầu trên máy ảo GitHub	322 giây
Máy đo	GitHub Actions Ubuntu 24.04.5 LTS, AMD EPYC 9V74 80-Core Processor, 4 luồng, 15983 MB RAM

Phần 9. Câu hỏi vấn đáp

Trả lời ngắn, có số, rồi mở minh chứng ở cột cuối. Thầy hỏi khác đi một chút thì vẫn dựa vào ý chính của câu trả lời. Cùng nội dung có ở tab **Ôn vấn đáp** của sheet phân công.

Câu hỏi về phần của bạn

Số sinh viên tăng gấp đôi, hoặc video lên 1080p thì sao?

Sửa ô chữ xanh trong bảng tính (Tổng tài khoản, hoặc bitrate video), bảng tự tính lại băng thông, số người cùng lúc, số bản API. Giải thích con số mới thay đổi vì sao.

Mở minh chứng: so-do-va-bang/bang-tai-nguyen-ip-quyen.xlsx, tab Tính tài nguyên

Vì sao không tách nhiều dịch vụ nhỏ (microservice)?

Tải ở mức này chưa cần, mà mỗi dịch vụ thêm ra đều phải triển khai, giám sát, xử lý lỗi mạng. 1 ứng dụng không giữ dữ liệu trong máy vẫn thêm bản được thoải mái.

Mở minh chứng: Báo cáo nhóm mục 3.4

Chạy nhiều bản API phải sửa gì?

Giới hạn request đếm trong Redis thay vì bộ nhớ từng bản; việc định kỳ tách sang worker; PgBouncer để tổng kết nối CSDL không tăng theo số bản; kiểm tra sức khoẻ tách "còn sống" với "sẵn sàng".

Mở minh chứng: cau-hinh-ma-nguon/hanni-server/infra/k8s/app/config.yaml (có chú thích từng dòng)

HPA có kịp đỡ đợt nộp bài 30 giây không?

Không kịp: HPA đo CPU mỗi 15 giây, bản mới cần vài chục giây mới sẵn sàng. Phải thêm bản trước giờ thi; HPA hợp với tải tăng dần.

Mở minh chứng: Báo cáo nhóm mục 5.6; lệnh scripts/kubectl -n hanni get hpa

Cải tiến của nhóm là gì, đánh đổi gì?

Lưu tạm khung lộ trình 60 giây, quá tải thì trả "thử lại sau", kiểm tra sức khoẻ chờ lâu hơn. Mức còn nhanh tăng 157 → 190 request/giây; quá tải chờ 5,0 → 0,73 giây. Đánh đổi: một phần lượt đọc bị từ chối.

Mở minh chứng: Báo cáo nhóm mục 6.1

Thao tác có thể bị yêu cầu

Đổi maxReplicas trong k8s/app/api.yaml rồi make deploy, xem get hpa; đổi 1 ô bảng tính; mở bảng Grafana "Mở rộng" chỉ ra lúc thêm bản.

Mở minh chứng: cau-hinh-ma-nguon/hanni-server/infra/README.md, mục "Sửa nhanh khi bảo vệ"

Câu hỏi chung ai cũng phải trả lời được

Vì sao thử 20 kết nối không chứng minh phục vụ được 1.000 sinh viên?

Thời gian trả lời không tăng đều: từ 10 tới 40 lượt/giây p95 chỉ từ 23 lên 52 ms, thêm 10 lượt nữa đã 261 ms. Mức nhỏ chưa chạm giới hạn nào nên không nói gì về điểm gãy. Kết quả chỉ đúng cho đúng máy, dữ liệu, cấu hình đã đo.

Mở minh chứng: Báo cáo nhóm mục 5.3 (đo thăm dò), 6.2

Tài khoản khác người dùng cùng lúc thế nào?

Tài khoản là số người có thể dùng; người dùng cùng lúc mới tạo tải. 1.000 tài khoản sinh ra 63 người khi tự học, 300 khi cả lớp xem video, 600 khi thi thử đồng loạt.

Mở minh chứng: Báo cáo nhóm mục 2.1–2.2; so-do-va-bang/bang-tai-nguyen-ip-quyen.xlsx

Vì sao video không đi qua API?

Cả lớp xem video cần khoảng 888 Mbps trong khi API chỉ khoảng 56 request/giây. API chỉ kiểm quyền và ký liên kết, tệp do Nginx (thực tế là CDN) phát.

Mở minh chứng: Báo cáo nhóm mục 3.2; cau-hinh-ma-nguon/hanni-server/infra/k8s/app/media.yaml

Thêm máy chủ có hết quá tải không?

Không, nếu điểm nghẽn ở CSDL hoặc băng thông. Phải đo để biết điểm nghẽn trước: ở lab, nghẽn đầu tiên là hàng chờ kết nối CSDL, sửa xong mới tới CPU của API.

Mở minh chứng: Báo cáo nhóm mục 6.1; bảng Grafana "Mở rộng"

Bản sao lưu thế nào mới có giá trị?

Khi đã khôi phục thử, so số dòng và mã băm, đo được thời gian. Nhóm đã xoá hẳn CSDL rồi khôi phục: số dòng khớp, RTO 52 giây.

Mở minh chứng: Báo cáo nhóm mục 5.4; data/rpo-rto.xlsx

Lên 10.000 hay 100.000 sinh viên thì làm gì?

10.000: CSDL máy riêng có bản sao, kho tệp + CDN bắt buộc, khoảng 5 bản API. 100.000: nhiều vùng, tự chuyển CSDL khi hỏng, tách kho phân tích. Chuyển mức khi số đo chạm ngưỡng, không làm trước.

Mở minh chứng: Báo cáo nhóm mục 6.4

Phần 10. Việc cần làm trước khi nộp và bảo vệ

Trước khi nộp

1. Đọc báo cáo nhóm `ho-so-nop/bao-cao/Bao-cao-nhom.pdf` và báo cáo cá nhân của bạn `ho-so-nop/bao-cao/ca-nhan/Lop_Nhom_06_MSSV_PhamHaiDang_BaoCaoCaNhan.docx`.
2. Tự chạy lại phần của bạn theo mục "Chạy lại". Ghi lại bạn đã tự làm gì, rồi điền vào chỗ "Tự làm: ....." ở mục 7 và mục 9 của báo cáo cá nhân.
3. Điền mã sinh viên, lớp, nhóm vào báo cáo cá nhân; đổi tên tệp theo mẫu `Lop_Nhom_DeTai_MSSV_BaoCaoCaNhan.docx`.
4. **Chỉ ký mục 10 (cam kết) khi đã tự chạy lại và hiểu được.** Mục 9 đã ghi rõ nhóm dùng trợ lý AI soạn bản nháp; người ký chịu trách nhiệm giải thích.
5. Báo Đăng khi xong để gom hồ sơ nộp lên Drive của thầy.

Trước buổi bảo vệ

1. Tập **mở đúng minh chứng trong 10 giây**: biết tệp kết quả của mình nằm ở đâu trong `ho-so-nop/` (bảng "Sản phẩm của bạn" ở phần 2).
2. Tập **1–2 thao tác** ở phần "Sửa và cấu hình trực tiếp": nói được tệp nào, dòng nào, lệnh áp dụng, cách kiểm tra.
3. Tập trả lời các câu ở phần Câu hỏi vấn đáp bằng lời của mình, có số.
4. Xem lại phần 1 (kiến thức nền): thầy có thể hỏi kiến trúc chung, không chỉ phần của bạn.

> Câu chốt khi bị hỏi khó: "Theo số đo của nhóm trên lab, trong điều kiện ... thì ... ; giới hạn là ... ; muốn chắc hơn thì đo thêm ...". Trả lời theo số đo và nêu giới hạn luôn được đánh giá cao hơn khẳng định chung chung.